

CURRICULUM VITAE



Miloš Vasić

AI Engineer · Software Engineer

LLM infrastructure, autonomous agents, and the governance that makes them trustworthy. Fleets over monoliths; anti-bluff, evidence-gated quality.

2009 ENGINEERING SINCE	140+ REPOSITORIES GOVERNED	43 LLM PROVIDERS UNIFIED	6+ CORE LANGUAGES
---	---	---	--

Інжынер — LLM-інфраструктура, аўтаномныя агенты і кіраванне, якое робіць іх надзейнымі.

- Email: milos85vasic@gmail.com
- Вэб: <https://milosvasic.ru> · <https://vasic.digital>
- GitHub: vasic-digital · HelixDevelopment · Server-Factory

Агульныя звесткі

AI/праграмны інжынер, які стварае сістэмы AI-распрацоўкі ад пачатку да канца — ад LLM-інфраструктуры з некалькімі пастаўшчыкамі і аўтаномных агентаў да ўзроўняў забеспячэння якасці і кіравання, якія гарантуюць іх сумленнасць. Я не ствараю дэманстрацыйныя версіі — я ствараю платформы. За 15 гадоў прафесійнай інжынернай дзейнасці (з 2009 года) у сферах мабільных SDK, інтэграцыі рэальнага часу з абсталяваннем і размеркаваных бэкэндаў цяпер засяроджваюся на адным: зрабіць аўтаномную AI-распрацоўку надзейнай у маштабах.

Я архітэктую флатыліі, а не маналіты — вялікія праграмныя прадукты, якія абапіраюцца на дзясяткі невялікіх, развязаных і незалежна пратэставаных модуляў, кожны з якіх атрымлівае агульны інжынерны Constitution і правяраецца дысцыплінай забеспячэння якасці з антыблефавым і дакументаваным падыходам. Асноўная мова — Go, з выкарыстаннем Kotlin/KMP, TypeScript/React, Python, Swift і Shell. Кіруючы прынцып, які прымяняецца механічна, а не проста дэкларуецца: функцыя лічыцца гатовай толькі тады, калі рэальны карыстальнік можа ёю скарыстацца і ёсць зафіксаваныя доказы гэтага.

Што я прыношу ў праект: здольнасць ператварыць AI-магчымасць ад навуковай ідэі ў кіраваную, самаправяральную сістэму, гатовую да прамысловай эксплуатацыі — LLM-маршрутызацыю, якая пацвярджае працаздольнасць кожнай мадэлі перад яе выкарыстаннем, агенты, што абмяркоўваюць і дасягаюць кансэнсусу замест здагадак, пласты памяці і RAG, якія не губляюць кантэкст, і цэлую экасістэму, дзе “тэсты зялёныя” ніколі не азначае “функцыя зламана”.

Асноўныя кампетэнцыі

- **AI / LLM-сістэмы:** абстракцыя LLM з некалькімі пастаўшчыкамі (40+), інтэграцыя MCP-інструментаў, RAG, vector-базы даных і embeddings, аркестрацыя агентаў (безгалаўныя CLI-агенты, граф-працоўныя працэсы, шматраўндовыя дэбаты/кансэнсус), планаванне (HiPlan/MCTS/Tree-of-Thoughts), LLMops, бенчмаркінг (SWE-bench/HumanEval/MMLU), праверка LLM, абарончыя бар’еры LLM, камп’ютарны зрок + LLM-зор.
- **Бэкэнд-інжынерыя:** Go (Gin), gRPC + Protobuf, HTTP/3 (QUIC), WebSockets, размеркаваныя сістэмы (уключаючы фармальныя спецыфікацыі TLA+), высокапрадукцыйныя REST-сэрвісы і канкурэнтныя працоўныя працэсы.

- **Дадзеныя:** PostgreSQL, SQLite, SQLCipher (шыфраванне на ўзроўні захоўвання), Redis, Neo4j, ClickHouse, аб'ектнае захоўванне (MinIO/S3/GCS/Azure).
- **Фронтэнд / крос-платформа:** TypeScript/React (Tailwind, Redux Toolkit, i18next), Angular, Electron, React Native, Kotlin Multiplatform, Android/Android TV (Kotlin), iOS (Swift), Tauri/Rust.
- **Інфраструктура / DevOps:** Docker і Compose, Kubernetes + Helm, Prometheus + Grafana, OpenTelemetry, QEMU/Libvirt/Parallels; CI/CD праз GitHub Actions, Gradle, Make.
- **Забеспячэнне якасці / інжынерныя якасці:** антыблефавая сістэма забеспячэння якасці з дакументаваным падыходам (HelixQA), тэставыя каркасы з мутацыйнымі бар'ерамі, `go test -race`, візуальнае рэгрэсійнае тэставанне, тэставанне праз ADB, SonarQube, скарынг бяспекі (semgrep/gosec/trivy/snyk/gitleaks/nancy).
- **Кіраванне інжынерным працэсам:** Constitution як падмадуль; бар'еры спадчыннасці і распаўсюджвання; дысцыпліна дакументавання і пакрыцця тэстамі ў флатыліі з 140+ рэпазіторыяў.

Змесціва

Абраныя праекты

Кіраванне і забеспячэнне якасці

- **HelixConstitution** — універсальны збор інжынерных правілаў, які распаўсюджваецца як падмадуль Git і наследуецца ў больш чым 140 рэпазіторыях: інжынернае права версіюецца і фіксуецца гэтак жа, як і код. Адзінае абнаўленне падмадуля ўдасканальвае правілы для ўсёй сістэмы, а працэс распаўсюджвання літаральна правярае кожны рэпазіторый-пакупнік на наяўнасць патрэбнага палажэння — кожная праверка суправаджаецца мутацыйным мета-тэстам, які даказвае, што сама праверка не з'яўляецца фікцыяй. Гэта ператварае «лепшыя практыкі, якіх людзі спадзяюцца прытрымлівацца» у спадчыннае, аўдытаванае і механічна прымусовае анты-блефнае права.
- **HelixQA** — аркестрацыя забеспячэння якасці па прынцыпе анты-блефу (Go), заснаваная на адным непахісным правіле: планка не «тэсты прайшлі», а «карыстальнікі могуць карыстацца функцыяй». Яна запуская пісьмовыя банкі тэстаў YAML і цалкам аўтаномныя сесіі забеспячэння якасці з выкарыстаннем LLM і камп'ютарнага зроку, якія адкрываюць рэальнае дастасаванне, правяраюць кожную дакументаваную функцыю, шукаюць недакументаваныя памылкі на платформах Android/Android TV/Web/Desktop і адмаўляюцца ставіць статус «ПРАЙШЛА» без захопленых сведчанняў працы — здымкаў экрана, лагаў logcat, відэазапісаў, трэйсаў стэка — а таксама білетаў на выпраўленне AI, гатовых да ўкаранення.

Распрацоўка AI і інфраструктура LLM

- **HelixAgent** — ансамблевы сэрвіс LLM прамысловага ўзроўню (Go/Gin), які не давае адзінай мадэлі: ён распаўсюджвае запыт па некалькіх пастаўшчыках, праводзіць структураванае шматраўндовыя дэбаты (Прапанова → Крытыка → Агляд → Сінтэз) і маршрутызуе паводле жывых верафікацыйных паказчыкаў з грацыёзным пераключэннем на рэзерв — усё гэта за OpenAI-сумяшчальным API з высокадаступным слоём даных, назіральнасцю і засцерагальнымі механізмамі. *Go, Gin, PostgreSQL, Redis, Prometheus/Grafana/OpenTelemetry, MCP, Neo4j/ClickHouse/Kafka.*

- **HelixCode** — размеркаваная платформа распрацоўкі AI, якая падзяляе працу на разумныя задачы з улікам залежнасцей паміж імі ў флоце працоўных вузлоў, кіраваным SSH, пасля чаго стварае кантрольныя кропкі і адкочвае змены, каб нічога не гублялася пры перапынку задачы; мадэлі выбіраюцца з улікам апаратнага забеспячэння, а поўны цыкл распрацоўкі — планаванне, стварэнне, тэставанне, рэфактарынг — ажыццяўляецца за REST/CLI/TUI/MCP. *Go, Gin, PostgreSQL, Redis, SSH, MCP, llama.cpp/Ollama.*
- **HelixLLM** — адзін бінарны файл, шэсць рэжымаў разгортвання: OpenAI- і Anthropic-сумяшчальны інферэнс праз HTTP/3, які маштабуецца ад ноўтбука да шматхастовага кластара з лакальным інферэнсам llama.cpp (CUDA/Metal/ROCm) і аўтаматычна выяўляемай, верафікавана ацэненай ланцужком рэзервовага пераключэння на воблака, што заўсёды дэградацыйнае да гарантавана лакальнай мадэлі. *Go, HTTP/3 QUIC, gRPC/SSE/Kafka, llama.cpp.*
- **LLMProvider / LLMOrchestrator / LLMsVerifier** — становішча інфраструктуры LLM: адзіны інтэрфейс для 43 пастаўшчыкаў з засцерагальнымі перапынкамі ланцужкоў, маніторынгам здароўя, паўторнымі спробамі з экспаненцыяльным затрымкай і сумленным (без жорстка зашытых рэзервовых варыянтаў) выяўленнем мадэляў; патокова-бяспечная кантрольная панель, якая запуская і кіруе бязгалоўнымі агентамі CLI (OpenCode, Claude Code, Gemini, Junie, Qwen Code) праз гібрыдны пратакол каналаў і файлаў; а таксама крыніца верафікацыйнай праўды, дзе абавязковая праверка «Ці бачыш ты мой код?» азначае, што толькі мадэлі, якія даказаны працуюць, калі-небудзь пазначаюцца прыдатнымі да выкарыстання ці экспартуюцца.
- **HelixMemory / HelixSpecifier** — уніфікаваны рухавічок кагнітыўнай памяці, які аб'ядноўвае чатыры найлепшыя бэкэнды (Mem0, Cognee, Letta, Graphiti) за адным інтэрфейсам з паралельным пошукам і пераранжыроўкай крыніц; а таксама рухавічок распрацоўкі на аснове спецыфікацый, які маштабуе ўласную цырымонію ў адпаведнасці з аб'ёмам працы і падмацоўвае спецыфікацыі шмат-агентнымі дэбатамі.
- **HelixTrack** — свабодная альтэрнатыва JIRA + Confluence (флагман лінейкі Helix-Track): Go-мікрасэрвісы з уніфікаваным API з маршрутызацыяй дзеянняў праз HTTP/3, шыфраваннем дан

Змесціва

Інструменты прафесійнага ўзроўню (vasic-digital utils)

- **Catalogizer** — шматпратаколльная, шыфраваная, самахостная сістэма кіравання медыякалекцыямі (Go/Gin + React), устойлівая да нестабільных сеткавых сховішчаў, пабудаваная на 21 паўторна выкарыстоўваемым падмодулі.
- **Courses-Creator** — канвеер пераўтварэння markdown у відэа AI з TTS і прайгравальнікамі для дэскапа, мабільных прылад і вэбу.
- **VisionEngine** — камп'ютарны зрок + шматправайдарскі інтэрфейс успрымання LLM з навігацыйнымі графамі.
- **DocProcessor · Docs Chain · Herald · task_bridge · Vasic Digital Набор паўторна выкарыстоўваемых модуляў** — мапаванне функцый для забеспячэння якасці, сінхранізацыя дакументаў і баз даных з кантролем зместу, апавяшчэнні на натуральнай мове, сінхранізацыя задач і дошак, а таксама бібліятэка стандартаў `digital.vasic.*`.

Аўтаматызацыя інфраструктуры (Server Factory)

- **Mail Server Factory** — дэкларатыўнае разгортванне JSON → поўнаасцю падрыхтаваныя Docker-серверы электроннай пошты для 12 тыпаў злучэнняў і 25 дыстрыбутываў Linux; паведамляе аб 439 прайшоўшых тэстах і чыстым кантрольным пункце SonarQube.
- **Server Factory Core Framework, Qemu-Utills, Parallels-Utills** — агульны рухавік разгортвання і інструменты для стварэння вобразаў віртуальных машын.

Мовы і інструменты (кароткі пералік)

Go · Kotlin · Kotlin Multiplatform · TypeScript · JavaScript · Python · Swift · Java · Rust · Shell · PL/pgSQL · TLA+ · Gin · gRPC · HTTP/3 · React · Angular · Electron · React Native · PostgreSQL · SQLite · SQLCipher · Redis · Neo4j · ClickHouse · Docker · Kubernetes · Prometheus · Grafana · OpenTelemetry · QEMU · GitHub Actions · Gradle · Make

Досвед

Інжынер праграмнага забеспячэння з 2009 года, уключаючы ўвесь жыццёвы цыкл распрацоўкі — планаванне, распрацоўку, кіраўніцтва камандай і дэплой. Поўная гісторыя ніжэй заснавана на пацверджаным запісе кандыдата (milosvasic.ru).

Штатныя пасады

- **Распрацоўнік SDK — Harness** (harness.io), Бялград, Сербія · 03/2020 – 12/2024. Галоўны распрацоўнік сямейства SDK для падраздзялення Feature Flag кампаніі, арыентаванага на ўсе асноўныя мабільныя платформы і далей. Кліенты і партнёры ўключалі AWS, Google і розныя банкі. *Тэхналогіі: Android, iOS, Flutter, React Native, TypeScript, JavaScript, Java, Kotlin, Swift, Go, Ruby.*
- **Інжынер праграмнага забеспячэння — Leica Geosystems** (leica-geosystems.com), Хербруг, Швейцарыя · 02/2016 – 02/2020. У асноўным распрацоўка для iOS і Android для найноўшых 3D-сканараў Leica Geosystems — рэальначасовая сувязь з абсталяваннем, апрацоўка даных і сінхранізацыя. Партнёр: Autodesk. *Тэхналогіі: Android, iOS, Java, Kotlin, Swift, C++.*
- **Распрацоўнік SDK — Bosch** (bosch.rs), Бялград, Сербія · 01/2010 – 01/2016. Галоўны распрацоўнік SDK для праекта Connected Vehicles — рэальначасовая сувязь Bluetooth з шынай OBD2, высокаэфектыўная апрацоўка і захоўванне даных. *Тэхналогіі: Android, Java, Kotlin.*

Змест

Іншыя праекты

- **TN-TECH** (tn-tech.co.rs), Нови-Сад, Сербія · няпоўная занятасць, з 03/2017. Праца на кампанію Globex Data (Канада і Швейцарыя) — Sekur (SekurMessenger), SekurMail, SekurSuite — і платформу BusRide. *Тэхналогіі: Android, Java, Kotlin, C++, Qt.*
- **Increment Loop** (incrementloop.com), Бялград, Сербія · няпоўная занятасць, з 09/2023. Дадатак Yuno. *Тэхналогіі: Android, Kotlin.*

- **Адкрытыя крыніцы / уласныя арганізацыі** — HelixTrack, Server Factory (Mail Server Factory, Parallels-Utills, Qemu-Utills) і Vasic Digital (Android-Toolkit, Network-Binder), падрабязней у раздзеле «Абраныя праекты» вышэй.

Публікацыі

- **«Fundamental Kotlin»** — аўтар самавыдання; апошняе перагледжанае выданне — верасень 2022 г. (Fundamental Kotlin, 3-е выданне). Таксама аўтар для выдавецтва Packt Publishing (Вялікабрытанія).

Адукацыя

- **Магістр сучасных інфармацыйных тэхналогій** — Універсітэт Singidunum, Бялград, Сербія · 2014.
- **Бакалаўр інфарматыкі і вылічальнай тэхнікі** — Універсітэт Singidunum, Бялград, Сербія · 2008.