

CURRICULUM VITAE



Miloš Vasić

AI Engineer · Software Engineer

LLM infrastructure, autonomous agents, and the governance that makes them trustworthy. Fleets over monoliths; anti-bluff, evidence-gated quality.

milos85vasic@gmail.com · milosvasic.ru · vasic.digital
GitHub: vasic-digital · HelixDevelopment · Server-Factory

2009

ENGINEERING SINCE

140+REPOSITORIES
GOVERNED**43**LLM PROVIDERS
UNIFIED**6+**

CORE LANGUAGES

Inženjer — LLM infrastruktura, autonomni agenti i upravljanje koje ih čini pouzdanim.

- Email: milos85vasic@gmail.com
- Web: <https://milosvasic.ru> · <https://vasic.digital>
- GitHub: vasic-digital · HelixDevelopment · Server-Factory

Sažetak

AI/inženjer softvera koji gradi sisteme za AI razvoj od početka do kraja — od LLM infrastrukture s više pružalaca usluga i autonomnih agenata do slojeva QA i upravljanja koji ih drže pod kontrolom. Ne isporučujem demo verzije; isporučujem platforme. Preko 15 godina profesionalnog inženjeringa (od 2009. godine) u oblasti mobilnih SDK-ova, integracije hardvera u realnom vremenu i distribuiranih backend sistema sada se usredsređuju na jedan cilj: učiniti autonomni AI razvoj pouzdanim na velikoj skali.

Projektujem flote, a ne monolite — velike aplikacije koje se oslanjaju na desetine malih, odvojenih i nezavisno testiranih modula, od kojih svaki nasleđuje zajednički inženjerski Constitution i proverava se kroz disciplinu QA zasnovanu na dokazima, bez varanja. Primarni jezik je Go, uz Kotlin/KMP, TypeScript/React, Python, Swift i Shell. Vodeći princip, koji se sprovodi mehanički a ne samo deklarativno: funkcionalnost je gotova tek kada je stvarni korisnik može koristiti i kada postoje prikupljeni dokazi koji to potvrđuju.

Šta donosim za sto: sposobnost da se AI mogućnost prevede iz istraživačke ideje u upravljani, samoverifikujući sistem prilagođen produkciji — LLM rutiranje koje dokazuje da svaki model zaista funkcioniše pre nego što mu se poveri, agenti koji raspravljaju i postižu konsenzus umesto da nagađaju, slojevi memorije i RAG koji ne gube kontekst, i čitav ekosistem povezan tako da „testovi su zeleni” nikada ne znači „funkcionalnost je pokvarena”.

Ključne kompetencije

- **AI / LLM sistemi:** apstrakcija LLM infrastrukture s više pružalaca usluga (40+ pružalaca), integracija alata za MCP, RAG, vector baze podataka i embeddings, orkestracija agenata (headless CLI agenti, grafički tokovi poslova, višestruka debata/konsenzus), planiranje (HiPlan/MCTS/Tree-of-Thoughts), LLMops, benchmarking (SWE-bench/HumanEval/MMLU), verifikacija LLM, odbrambeni LLM sigurnosni mehanizmi, računarski vid + LLM-vid.
- **Backend inženjering:** Go (Gin), gRPC + Protobuf, HTTP/3 (QUIC), WebSockets, distribuirani sistemi (uključujući formalne specifikacije TLA+), visokopropusni REST servisi i konkurentni radnici.
- **Podaci:** PostgreSQL, SQLite, SQLCipher (šifrovanje u mirovanju), Redis, Neo4j, ClickHouse, objekti skladištenja (MinIO/S3/GCS/Azure).
- **Frontend / cross-platform:** TypeScript/React (Tailwind, Redux Toolkit, i18next), Angular, Electron, React Native, Kotlin Multiplatform, Android/Android TV (Kotlin), iOS (Swift), Tauri/Rust.

- **Infra / DevOps:** Docker i Compose, Kubernetes + Helm, Prometheus + Grafana, OpenTelemetry, QEMU/Libvirt/Parallels; CI/CD preko GitHub Actions, Gradle, Make.
- **QA / inženjering kvaliteta:** QA zasnovan na dokazima bez varanja (HelixQA), okviri za izazove s mutacionim kapijama, `go test -race`, testiranje vizuelne regresije, testiranje uređaja preko ADB-a, SonarQube, skeniranje sigurnosti (semgrep/gosec/trivy/snyk/gitleaks/nancy).
- **Upravljanje inženjeringom:** Constitution kao podmodul; kapije nasleđivanja i propagacije; disciplina dokumentacije i pokrivenosti kroz flotu od 140+ repozitorijuma.

Izabrani projekti

Upravljanje i kontrola kvaliteta

- **HelixConstitution** — univerzalni inženjerski priručnik distribuiran kao Git podmodul i nasleđen u preko 140 repozitorijuma: inženjerski zakon isporučuje se i verzionira tačno kao kod. Jedno ažuriranje podmodula unapređuje pravila za ceo sistem, a propagacioni filteri bukvalno pretražuju svaki repozitorijum koji ga koristi kako bi pronašli obaveznu klauzulu — svaki filter uparen je sa mutacionim metatestom koji dokazuje da sam filter nije lažan. Pretvara „najbolje prakse koje ljudi žele da prate” u nasleđeno, proverljivo i mehanički sprovodivo antiblef zakonodavstvo.
- **HelixQA** — antiblef orkestracija kontrole kvaliteta (Go) zasnovana na jednom nepopustljivom pravilu: mera nije „testovi prolaze”, već „korisnici mogu da koriste funkciju”. Pokreće pisane YAML test-banke i potpuno autonomne LLM-i-vizuelne sesije kontrole kvaliteta koje otvaraju pravu aplikaciju, proveravaju svaku dokumentovanu funkciju, tragaju za nedokumentovanim greškama na Androidu/Android TV/ Webu/desktopu i odbijaju da ocene prolazak bez snimljenih dokaza u realnom vremenu — snimaka ekrana, logcat-a, video-zapisa, stek traga — plus AI-tiketa spremnih za ispravku.

Razvoj AI i LLM infrastruktura

- **HelixAgent** — produkcijski ansambl LLM usluga (Go/Gin) koja odbija da veruje jednom modelu: šalje prompt na više provajdera, vodi strukturisanu višestepenu debatu (Predlog → Kritika → Pregled → Sinteza) i usmerava prema rezultatima provere uživo sa postupnim povlačenjem — sve iza OpenAI-kompatibilnog API interfejsa sa HA slojem podataka, opservabilnošću i zaštitnim mehanizmima. *Go, Gin, PostgreSQL, Redis, Prometheus/Grafana/OpenTelemetry, MCP, Neo4j/ClickHouse/Kafka.*
- **HelixCode** — distribuirana AI razvojna platforma koja deli posao na inteligentne, zavisne zadatke raspoređene na SSH-floti radnika, a zatim pravi kontrolne tačke i povlači izmene tako da ništa nikada ne bude izgubljeno ako se zadatak prekine; izbor modela svestan hardvera i ceo ciklus planiranja/izrade/testiranja/refaktorisanja iza REST/CLI/TUI/MCP. *Go, Gin, PostgreSQL, Redis, SSH, MCP, llama.cpp/Ollama.*
- **HelixLLM** — jedan binarni fajl, šest režima implementacije: OpenAI- i Anthropic-kompatibilno zaključivanje preko HTTP/3 koje skaliramo od laptopa do višenamenskog klastera, sa lokalnim zaključivanjem preko llama.cpp (CUDA/Metal/ROCm) i automatski otkrivenim, verifikaciono ocenjenim lancem rezervnih rešenja u oblaku koji uvek degradira na zagarantovani lokalni model. *Go, HTTP/3 QUIC, gRPC/SSE/Kafka, llama.cpp.*
- **LLMProvider / LLMOrchestrator / LLMsVerifier** — kičma LLM infrastrukture: jedan interfejs preko 43 provajdera sa prekidačima strujnog kola, monitoringom zdravlja, ponovnim pokušajima sa eksponencijalnim odlaganjem i poštenim (bez unapred definisanih rezervnih rešenja) otkrivanjem

modela; thread-safe kontrolna ravan koja pokreće i upravlja headless CLI agentima (OpenCode, Claude Code, Gemini, Junie, Qwen Code) preko hibridnog protokola cevi i fajlova; i izvor istine za verifikaciju čiji obavezni filter „Vidiš li moj kod?” znači da se samo modeli za koje je dokazano da zaista rade označavaju kao upotrebljivi ili izvoze.

- **HelixMemory / HelixSpecifier** — ujedineni kognitivno-memorijski pogon koji spaja četiri vodeća backend-a (Mem0, Cognee, Letta, Graphiti) iza jednog interfejsa sa paralelnim pretraživanjem i ponovnim rangiranjem rezultata iz više izvora; i pogon za razvoj vođen specifikacijama koji prilagođava sopstvenu proceduru obimu posla i podržava specifikacije višestrukom agentskom debatnom.
- **HelixTrack** — alternativa slobodnog sveta za JIRA + Confluence (zastavni projekat Helix-Track linije): Go mikrousluge sa ujedinenim API interfejsom usmerenim akcijama preko HTTP/3, SQLCipher enkripcijom u mirovanju i klijentima za Web/Desktop/Android/iOS.

Alati profesionalnog nivoa (vasic-digital utils)

- **Catalogizer** — višeprotokolni, enkriptovani, samostalno hostovani sistem za upravljanje medijskim kolekcijama (Go/Gin + React), otporan na nestabilna mrežna skladišta, izgrađen na 21 ponovo upotrebljivom potmodulu.
- **Courses-Creator** — pipeline za konverziju markdown-a u video (AI) sa TTS i plejerima za desktop, mobilne i veb platforme.
- **VisionEngine** — računarski vid + višekorisnički LLM interfejs percepcije sa navigacionim grafovima.
- **DocProcessor · Docs Chain · Herald · task_bridge · Vasic Digital Paket ponovo upotrebljivih modula** — mapiranje funkcionalnosti za QA, sinhronizacija dokumenata/baza podataka sa heširanim sadržajem, obaveštenja na prirodnom jeziku, sinhronizacija zadataka/tabli i flota `digital.vasic.*` standardne biblioteke.

Automatizacija infrastrukture (Server Factory)

- **Mail Server Factory** — deklarativni JSON → potpuno konfigurisani, Dockerizovani mejl serveri za 12 vrsta konekcija i 25 Linux distribucija; izveštava o 439 uspešno položenih testova i čistoj SonarQube kapiji.
- **Server Factory Osnovni okvir, Qemu-Utills, Parallels-Utills** — zajednički provisioning pogon i alati za kreiranje VM slika.

Jezici i alati (kratak spisak)

Go · Kotlin · Kotlin Multiplatform · TypeScript · JavaScript · Python · Swift · Java · Rust · Shell · PL/pgSQL · TLA+ · Gin · gRPC · HTTP/3 · React · Angular · Electron · React Native · PostgreSQL · SQLite · SQLCipher · Redis · Neo4j · ClickHouse · Docker · Kubernetes · Prometheus · Grafana · OpenTelemetry · QEMU · GitHub Actions · Gradle · Make

Iskustvo

Softverski inženjer od 2009. godine, sa iskustvom u celom razvojnom ciklusu — planiranje, razvoj, vođenje tima i implementacija. Ceo istorijat u nastavku preuzet je iz potvrđenog zapisa kandidata (milosvasic.ru).

Stalni poslovi

- **SDK Developer — Harness** (harness.io), Beograd, Srbija · 03/2020 – 12/2024. Glavni developer porodice SDK-ova za odeljenje Feature Flag kompanije, sa fokusom na sve glavne mobilne platforme i šire. Klijenti i partneri uključivali su AWS, Google i razne banke. *Tehnologije: Android, iOS, Flutter, React Native, TypeScript, JavaScript, Java, Kotlin, Swift, Go, Ruby.*
- **Softverski inženjer — Leica Geosystems** (leica-geosystems.com), Herbrugg, Švajcarska · 02/2016 – 02/2020. Primarno iOS i Android razvoj za vrhunske 3D skenere kompanije Leica Geosystems — komunikacija u realnom vremenu sa hardverom, obrada podataka i sinhronizacija. Partner: Autodesk. *Tehnologije: Android, iOS, Java, Kotlin, Swift, C++.*
- **SDK Developer — Bosch** (bosch.rs), Beograd, Srbija · 01/2010 – 01/2016. Glavni SDK developer na projektu Connected Vehicles SDK — komunikacija u realnom vremenu sa OBD2 magistralom, obrada podataka visokih performansi i njihovo čuvanje. *Tehnologije: Android, Java, Kotlin.*

Ostale profesionalne aktivnosti

- **TN-TECH** (tn-tech.co.rs), Novi Sad, Srbija · honorarno, od 03/2017. Rad za Globex Data (Kanada i Švajcarska) — Sekur (SekurMessenger), SekurMail, SekurSuite — i platformu BusRide. *Tehnologije: Android, Java, Kotlin, C++, Qt.*
- **Increment Loop** (incrementloop.com), Beograd, Srbija · honorarno, od 09/2023. Aplikacija Yuno. *Tehnologije: Android, Kotlin.*
- **Otvoreni kod / sopstvene organizacije** — HelixTrack, Server Factory (Mail Server Factory, Parallels-Utills, Qemu-Utills) i Vasic Digital (Android-Toolkit, Network-Binder), detaljnije opisano u odeljku Izabrani projekti.

Publikacije

- **Fundamentalni Kotlin** — samostalno objavljeni autor; poslednje revidirano izdanje septembar 2022. (Fundamentalni Kotlin, 3. izdanje). Takođe autor za Packt Publishing (Velika Britanija).

Obrazovanje

- **M.Sc, Savremene informacione tehnologije** — Univerzitet Singidunum, Beograd, Srbija · 2014.
- **B.Sc, Informatika i računarstvo** — Univerzitet Singidunum, Beograd, Srbija · 2008.